

학술제 주제

주제 개요

그래프 신경망 기반 조직적 어뷰징 네트워크 탐지 (Graph Neural Network-based Systematic Abusing Network Detection)

YelpZip 원본 데이터셋을 활용하여
GNN기반 조직적 어뷰징 네트워크 탐지 모델을
구축하여 이를 대시보드로 나타내는 것이
본 대회 of 핵심이다.

yelpzip.csv (410.87 MB)

Detail Compact Column 8 of 8 columns

#	user_id	prod_id	rating	label	date	text	tag
0	5844	0	1.0	-1	2014-11-16	Drinks were bad, the hot chocolate was watered down and the latte had a burnt taste to it. The food ...	fake
1	5845	0	1.0	-1	2014-09-08	This was the worst experience I've ever had a casual coffee/light fare place. The server disappear...	fake
2	5846	0	3.0	-1	2013-10-06	This is located on the site of the old Spruce St. Video. The wild coffee is very good and the pastri...	fake
3	5847	0	5.0	-1	2014-11-30	I enjoyed coffee and breakfast twice at Front Street...	fake

학술제 주제

주제 개요

1. 그래프 신경망(GNN)의 정의 및 개념

그래프 신경망(GNN, Graph Neural Network)이란 데이터 사이의 복잡한 관계를 ‘점(node)’과 ‘선(edge)’으로 이루어진 그래프 구조로 표현하고, 이를 인공지능이 학습할 수 있도록 설계된 신경망 구조를 의미한다.

기존의 일반적인 인공지능 모델이 데이터 하나하나를 개별적인 정보로 처리했다면, GNN은 특정 데이터가 주변의 다른 데이터와 어떤 연결 고리를 가지고 있는지, 즉 **상호작용과 맥락**을 함께 학습한다.

예를 들어, 소셜 네트워크에서 ‘나’라는 노드는 ‘친구’라는 노드들과 선으로 연결되어 있으며, GNN은 이러한 연결 관계를 통해 나의 특성을 더 정확하게 파악해 낼 수 있다.

학술제 주제

주제 개요

2. 사기 리뷰 탐지에 GNN이 필수적인 이유

기존의 텍스트 분석(NLP)만으로는 사기 리뷰를 완벽히 잡아내는 데 한계가 있다.
우리가 GNN을 도입해야 하는 이유는 다음과 같다.

① 개별 데이터가 아닌 '조직적 패턴' 포착

사기 리뷰는 단순히 글자 하나하나의 문제가 아니라, 특정 세력이 조직적으로 움직이는 **네트워크의 문제**이다.

사용자 기반 연결: 한 명의 유저가 여러 개의 사기 리뷰를 작성하는 경우, 이 리뷰들은 해당 유저를 중심으로 연결된다.

시간 및 장소 기반 연결: 특정 식당에 짧은 기간 동안 갑자기 수십 개의 평점이 쏟아진다면, 이는 시간이라는 선으로 연결된 의심스러운 집단 행동으로 볼 수 있다. GNN은 이러한 복잡한 연결망을 한눈에 파악하여, 겉보기에 멀쩡한 리뷰라도 그 배후에 숨겨진 사기 네트워크를 찾아낼 수 있다.

학술제 주제

주제 개요

② 정보의 전파를 통한 정확도 향상

GNN의 핵심 원리는 '주변 정보의 전파'이다.

GNN은 그래프 위에서 이러한 의심 정보를 주고받으며 학습하기 때문에 단독 데이터만 볼 때보다 훨씬 높은 정확도로 범죄 집단을 식별할 수 있다.

③ 변칙적인 수법에 대한 유연한 대응

특정 상품에 집중하거나 특정 계정을 돌려쓰는 **구조적인 행동 패턴**까지 숨기기는 매우 어렵다.

GNN은 데이터 간의 연결 방식(edge)을 어떻게 설계하느냐에 따라 새로운 사기 수법도 효과적으로 방어할 수 있는 강력한 도구가 된다.

학술제 주제

데이터셋

Yelp Dataset

: Yelp의 실제 추천/필터링 시스템 알고리즘을 거쳐 수집된

약 60만 개 이상의 대규모 식당 및 비즈니스 리뷰 원본 데이터이다.

본 대회에의 메인 데이터셋으로, 참가자들은 이 데이터를 바탕으로 숨겨진 사기 네트워크를 발굴해 내야 한다.

활용 목적: 제공된 텍스트를 자연어 처리 모델로 임베딩하여 그래프의 node로 만들고,
대시보드 시각화 단계에서 작업장 리뷰의 증거 자료로 활용한다.

YelpZip 원본 리뷰 데이터셋 - 컬럼(Column) 상세 설명

text : 리뷰의 원본 텍스트.

자연어 처리(BERT 등)를 통한 임베딩 추출 및 대시보드 시각화 시 ‘사기 증거’로 화면에 보여줄 필수 데이터

user_id: 리뷰를 작성한 유저의 고유 식별자

prod_id: 대상 식당/상품의 고유 식별자

label : 정상 리뷰(0)와 사기/위장 스팸 리뷰(1)를 구분하는 타겟 변수이며, 모델의 최종 탐지 목표

[중요] Label 변환 주의사항

기존 YelpZip 데이터는 사기가 -1, 정상이 1 로 라벨링 되어 있습니다.

반드시 필수 전처리(**사기는 1, 정상은 0**으로 라벨을 변환)를 실행한 후 진행해야 합니다.

Date: 리뷰가 작성된 날짜

rating: 유저가 부여한 별점 (1~5점). 노드의 추가 정보로 활용 가능

tag: 리뷰에 부여된 추가 메타 태그 정보

참고용 데이터셋

① YelpChi 데이터셋 (시카고 지역 식당/호텔 리뷰)

목적: 가짜/스팸 리뷰 탐지

노드 : 각각의 Review가 하나의 점이 된다.

정답지 : 0 (정상 리뷰), 1 (스팸 리뷰)

그래프 연결 방식 (3가지 엣지 참고):

이 데이터셋에 피쳐로 들어있는 `net_rur`, `net_rtr`, `net_rsr` 의 의미는 다음과 같다.

R-U-R (Review-User-Review): 같은 사용자가 작성한 리뷰들끼리 선으로 연결

R-T-R (Review-Time-Review): 같은 식당/호텔에 대해 같은 달에 작성된 리뷰들끼리 연결

R-S-R (Review-Star-Review): 같은 식당/호텔에 대해 같은 별점을 준 리뷰들끼리 연결

참고용 데이터셋

② Amazon 데이터셋 (아마존 악기 카테고리 리뷰)

목적: 리뷰 자체가 아닌 사기꾼 사용자 탐지

노드: 각각의 사용자가 하나의 점이 된다.

정답지: 0 (정상 유저), 1 (사기꾼 유저)

그래프 연결 방식 (3가지 엣지 참고): 이 데이터셋에 피쳐로 들어있는 net_upu, net_usu, net_uvu 의 의미는 다음과 같다.

U-P-U (User-Product-User): 적어도 하나 이상 동일한 제품에 리뷰를 남긴 사용자들끼리 연결

U-S-U (User-Star-User): 동일한 제품에 같은 별점을 준 사용자들끼리 연결

U-V-U (User-Vocab/View-User): 서로 작성한 리뷰 본문의 텍스트 유사도(TF-IDF 기준)가 상위 5% 이내로 아주 비슷한 사용자들끼리 연결

학술제 주제

참가자 가이드라인 필수 사항 (※ 미준수 시 감점)

1. 샘플링 및 분할 규정

: 먼저 샘플링 후 데이터 분할하도록 합니다.

① 서브그래프(Sub-graph) 샘플링 전략

- 무작위 추출 금지: 단순 무작위 추출은 노드 간 연결성을 파괴하여 GNN 학습을 불가능하게 하므로 금지합니다.
- 밀도 중심 샘플링: 아래의 추천 전략을 활용하여 관계가 조밀하게 엮인 **1만 개~5만 개** 사이의 노드를 추출하세요.

해당 전략들을 여러 개 사용하거나 다른 전략을 사용하여도 됩니다.

- 전략 A: 리뷰가 집중된 상위 N개 식당(Product) 중심 추출
- 전략 B: 왕성하게 활동하는 상위 N명 유저(User) 중심 추출
- 전략 C: 특정 연도/월 등 특정 타임라인(Time-window) 중심 추출

학술제 주제

참가자 가이드라인 필수 사항 (※ 미준수 시 감점)

1. 샘플링 및 분할 규정

: 먼저 샘플링 후 데이터 분할하도록 합니다.

② 데이터 분할 규칙

- **분할 시점**: 반드시 위 전략에 따라 샘플링이 완료된 서브그래프 내에서 데이터를 분할해야 합니다.
- **분할 비율**: 서브그래프 내의 노드를 학습용 80%(train/valid 비율은 80% 안에서 무관), 시험용 20%의 비율로 분할하여 사용하십시오.
- **재현성 확보**: 성능 평가의 신뢰도를 위해 분할 시 사용한 코드와 random_state 등 하이퍼파라미터를 보고서에 명시해야 합니다.

학술제 주제

참가자 가이드라인 필수 사항 (※ 미준수 시 감점)

2. 데이터 가공 규정 준수

: 본 대회는 Kaggle의 원본 데이터를 사용하므로, 아래 규정에 맞게 참가자가 직접 전처리를 수행해야 합니다.

라벨 변환: 원본의 label 컬럼 값 중 사기(-1)를 1로, 정상(1)을 0으로 반드시 변환해야 합니다.

학술제 주제

참가자 가이드라인 필수 사항 (※ 미준수 시 감점)

3. GNN 모델 사용 필수

: 본 대회 목적은 그래프 네트워크의 이해와 활용에 있습니다. 따라서 반드시 GNN 계열의 모델을 핵심으로 사용해야 하며, 단순 머신러닝/딥러닝 모델만 단독으로 사용할 경우 큰 감점이 부여됩니다.

GNN 모델 구조 설계 조건: 통일성 있는 평가를 위해 아래의 노드 및 엣지 구성 기준을 준수해 주세요.

노드: 리뷰 단위로 고정합니다.

엣지(Edge): 기본 Relation 1개 + 커스텀 Relation 1개 이상을 반드시 포함해야 합니다.

학술제 주제

참가자 가이드라인 필수 사항 (※ 미준수 시 감점)

3. GNN 모델 사용 필수

GNN 모델 구조 설계 조건: 통일성 있는 평가를 위해 아래의 노드 및 엣지 구성 기준을 준수해 주세요.

노드: 리뷰 단위로 고정합니다.

엣지(Edge): 기본 Relation 1개 + 커스텀 Relation 1개 이상을 반드시 포함해야 합니다.

기본 Relation (택 1 필수): 동일 사용자 기반(R-U-R), 동일 기간 기반(R-T-R), 동일 별점 기반(R-S-R) 중 최소 하나를 포함하세요.

커스텀 Relation (창의성 평가 요소): 참가팀의 도메인 지식과 아이디어를 발휘하여 창의적으로 설계해 주십시오. 가이드로 제공된 데이터셋(YelpChi, Amazon)은 좋은 참고 자료일 뿐입니다. 참가자분들만의 새로운 연결 방식과 파생 변수를 설정해 보시기를 적극 권장합니다.

학술제 예선 및 본선

예선 제출 가이드라인 (진행 기간: 5/2~5/15 | 제출일 : 5/15일 오후 1시)

수행 미션:

데이터 샘플링 및 전처리: 서브그래프 추출 및 텍스트 임베딩 등

그래프 네트워크 설계: 파생 변수 생성 및 커스텀 엣지 구축

GNN 모델링 및 최적화: 다양한 GNN 계열 모델(GCN, GAT, GraphSAGE 등) 비교 실험 및 성능 튜닝

제출물:

① 분석 보고서 (PDF):

전처리 과정, 모델 선택 이유, 엣지 설계의 논리적 근거 등을 상세히 담은 줄글 형태의 자유 양식 보고서 (5~20 page 내외, 상세 양식은 하단의 '4. 보고서 양식' 참고)

필수적으로 test set에 대한 모델의 **PR-AUC**와 **Macro F1** 성능지표를 포함해야 합니다

② 예선용 제출 코드

학술제 예선 및 본선

본선 제출 가이드라인 (진행 기간: 5/16~5/23 / 예선 통과 팀 한정 | **제출일: 5/22 오전 1시**)

예선에서 만든 GNN 모델의 결과를 바탕으로, 사기 리뷰 네트워크의 구조적 특징을 시각적이고 직관적으로 보여주는 단계입니다.

수행 미션:

GNN의 설명 가능성을 살린 시각화 로직 구현

대시보드(Streamlit, Dash 등) 형태의 웹 UI/UX 구현

청중을 설득할 수 있는 스토리텔링 및 발표 자료 제작

학술제 예선 및 본선

본선 제출 가이드라인 (진행 기간: 5/16~5/23 / 예선 통과 팀 한정 | 제출일: 5/22 오전 1시)

예선에서 만든 GNN 모델의 결과를 바탕으로, 사기 리뷰 네트워크의 구조적 특징을 시각적이고 직관적으로 보여주는 단계입니다.

제출물:

- ① 발표용 PPT (PDF 변환 제출)
- ② 업데이트된 분석 보고서 (PDF): 예선 제출본을 바탕으로 본선 기간 동안 발전된 로직이나 수정된 모델 내용이 있다면 이를 반영하여 최종 제출
- ③ 시각화 결과물 : 대시보드 URL 링크 또는 데모 구동 영상
- ④ 최종 코드

학술제 채점 기준

예선 점수 (총 100점)

평가 부문 (배점)	세부 항목 (배점)	심사 기준
GNN 분류 모델 성능 (10점)	PR-AUC 및 MACRO F1 (10점)	제출한 보고서에 나오는 결과 반영
논리성 (90점)	데이터 (20점)	적절한 전처리, EDA 및 데이터 분석 기법을 사용했는지?
	논리성 (20점)	GNN 모델 구축 과정이 논리적으로 잘 맞고 근거가 명확한지?
	창의성 (25점)	기존에 생각하기 어려웠던 참신한 관점으로 문제에 접근했는지?
	실효성 (25점)	현실적으로 이 모델과 분석 결과가 실무적 의미를 가지는지?

학술제 채점 기준

본선 점수 (총 100점)

평가 부문 (배점)	세부 항목 (배점)	심사 기준
GNN 분류 모델 성능 (10점)	PR-AUC 및 MACRO F1 (10점)	제출한 보고서에 나오는 결과 반영
논리성 (40점)	데이터 (5점)	적절한 전처리, EDA 및 데이터 분석 기법을 사용했는지?
	논리성 (5점)	GNN 모델 구축 과정이 논리적으로 잘 맞고 근거가 명확한지?
	창의성 (15점)	기존에 생각하기 어려웠던 참신한 관점으로 문제에 접근했는지?
	실효성 (15점)	현실적으로 이 모델과 분석 결과가 실무적 의미를 가지는지?
시각화 (40점)	시각적 설명력 (20점)	정상 네트워크와 사기(스팸) 네트워크의 구조적 특징과 관계성이 직관적으로 명확하게 구분되도록 시각화했는지?
	UI/UX 완성도 (20점)	대시보드(웹 등)가 실제 분석 환경에서 활용하기 적합하도록 직관적이고 완성도 높게 구현되었는지?
발표 점수 (10점)	전달력 (10점)	청중들에게 설득력 있는 발표였는지?

학술제 보고서 양식

본선 제출 가이드라인 <보고서 제출 양식>

1. 모델링 목표 정의

2. 데이터 구성 및 전처리 과정

2-1 사용 데이터

2-2. 전처리 내용

2-3. 파생 변수 및 그래프 엣지 설계 근거

3. 모델 선택 이유와 적용 과정

3-1. 선택한 모델

3-2. 모델 선택 이유

3-3. 모델 적용 과정

4. 모델 성능 평가 & 결과 해석

4-1. 평가 지표

4-2. 모델 성능 결과

(반드시 PR-AUC와 MACRO F1 점수 포함)

4-3. 결과 해석

5. 모델 기반 인사이트 및 활용 방안

6. 모델링의 한계와 보완 계획

7. 참고 코드(선택)

8. 추가 참고 자료(선택)

학술제 보고서 양식

본선 제출 가이드라인 <보고서 규격>

- 1.용지 규격: A4
- 2.폰트/디자인: 자유 (단, 가독성이 좋은 폰트 사용 권장)
- 3.본문 글자 크기: 11pt 고정 (제목, 목차, 도표 내 글자 크기는 자유)
- 4.여백 및 줄간격: 각 프로그램(한글/워드)의 기본 설정값 유지
- 5.분량: 5페이지 ~ 20페이지 이내 (표지 및 목차 제외)